طراحی یک روش تنظیم تطبیقی ضریب β برای بهبود پایداری و کارایی الگوریتم DPO در مدل‌های زبانی کدنویس:

عارف گنجائی ساری- گروه مهندسی کامپیوتر، دانشکده فنی مهندسی، دانشگاه آزاد اسلامی واحد غرب، شهر تهران کشور ایران
Aref.ganjaee1@yahoo.com

چکیده
هم‌ترازسازی مدل‌های زبانی بزرگ با ترجیحات انسانی یکی از چالش‌های اساسی در توسعه سامانه‌های هوشمند، به‌ویژه در حوزه مدل‌های زبانی کدنویس، به‌شمار می‌رود. الگوریتم Direct Preference Optimization (DPO) به‌عنوان جایگزینی ساده‌تر برای روش‌های مبتنی بر یادگیری تقویتی از بازخورد انسانی معرفی شده است، اما عملکرد آن به‌شدت به ضریب β وابسته است؛ پارامتری که در اغلب پژوهش‌های پیشین به‌صورت ثابت در نظر گرفته می‌شود. این فرض می‌تواند منجر به ناپایداری آموزش، افزایش فاصله از سیاست مرجع و کاهش کارایی مدل در شرایط آموزشی ناهمگن شود. در این مقاله، یک چارچوب مفهومی برای تنظیم تطبیقی ضریب β در الگوریتم DPO ارائه می‌شود که شدت اعمال ترجیحات انسانی را متناسب با وضعیت لحظه‌ای مدل تنظیم می‌کند. روش پیشنهادی با بهره‌گیری از سیگنال‌های درونی مدل، از جمله میزان تمایز بین پاسخ‌های ترجیحی و ناترجیحی و فاصله از سیاست مرجع، تلاش می‌کند تعادلی میان پایداری آموزش و کارایی یادگیری برقرار سازد. تحلیل کیفی ارائه‌شده نشان می‌دهد که تنظیم تطبیقی β می‌تواند بدون افزودن پیچیدگی‌های محاسباتی یا نیاز به مدل پاداش، به بهبود رفتار آموزشی DPO کمک کند. این چارچوب مفهومی می‌تواند مبنایی برای توسعه و ارزیابی تجربی روش‌های پیشرفته‌تر هم‌ترازسازی مبتنی بر ترجیحات انسانی در پژوهش‌های آتی باشد.

واژگان کلیدی
هم‌ترازسازی مدل‌های زبانی، بهینه‌سازی ترجیحات مستقیم، تنظیم تطبیقی β، مدل‌های زبانی کدنویس، پایداری آموزش، یادگیری مبتنی بر ترجیحات انسانی، Direct Preference Optimization(DPO).

مقدمه:

مدل‌های زبانی بزرگ (LLMs) که اغلب به‌صورت خودنظارتی و بر پایه‌ی مجموعه‌داده‌های بسیار عظیم آموزش می‌بینند، در سال‌های اخیر به ستون اصلی سامانه‌های هوش مصنوعی مدرن تبدیل شده‌اند[1]. این مدل‌ها به دلیل آنکه بر روی داده‌های تولیدشده توسط میلیون‌ها انسان با اهداف، مقاصد، ارزش‌ها و مهارت‌های متفاوت آموزش دیده‌اند، مجموعه‌ای گسترده از رفتارهای مفید و نامطلوب را هم‌زمان یاد می‌گیرند[1]. بخشی از این الگوهای یادگرفته‌شده ممکن است شامل خطاهای رایج انسانی، سوگیری‌ها یا پاسخ‌هایی باشند که با ارزش‌ها و ترجیحات مطلوب ما هم‌خوانی ندارند. بنابراین انتخاب، پالایش و تقویت رفتارهای مطلوب از میان طیف گسترده توانایی‌های مدل، برای ساخت سامانه‌های هوش مصنوعی قابل‌اعتماد، ایمن و قابل‌کنترل ضروری است[1]. برای دستیابی به این هدف، روش‌های هم‌ترازسازی (Alignment) معرفی شده‌اند که تلاش می‌کنند مدل را با ترجیحات انسانی منطبق کنند[1]. رایج‌ترین چارچوب در این حوزه، یادگیری تقویتی مبتنی بر بازخورد انسانی (RLHF) است که در آن با جمع‌آوری ترجیحات انسانی نسبت به جفت‌پاسخ‌ها و آموزش یک مدل پاداش، رفتار مدل به‌گونه‌ای تنظیم می‌شود که خروجی‌های مطلوب‌تری تولید کند. هم‌ترازسازی رفتار مدل‌های زبانی با ارزش‌ها و انتظارات انسانی، به‌ویژه در کاربردهایی که حساسیت اخلاقی یا عملی دارند، اهمیت فزاینده‌ای یافته است[1]. در سال‌های اخیر، RLHF به رویکرد استاندارد برای تنظیم دقیق مدل‌های زبانی بزرگ تبدیل شده و نقش مهمی در افزایش ایمنی، دقت و سازگاری این مدل‌ها ایفا کرده است[1]. با وجود این موفقیت‌ها، RLHF همچنان با چالش‌های اساسی مواجه است؛ از جمله نیاز به آموزش مدل پاداش جداگانه، استفاده از الگوریتم‌های یادگیری تقویتی پرهزینه و ناپایدار، و وابستگی شدید به نمونه‌گیری‌های متعدد از مدل. این پیچیدگی‌ها باعث شده پژوهشگران به‌دنبال رویکردهایی ساده‌تر، پایدارتر و کم‌هزینه‌تر برای یادگیری ترجیحات انسانی باشند. در همین راستا، الگوریتم Direct Preference Optimization (DPO) معرفی شده است که با حذف کامل مرحله یادگیری تقویتی و مدل پاداش، فرایند هم‌ترازی را به‌شکل مستقیم و مؤثر انجام می‌دهد[1].برای روشن‌تر شدن تفاوت این دو رویکرد، در ادامه ساختار کلی RLHF و DPO به‌صورت شماتیک نمایش داده شده است.

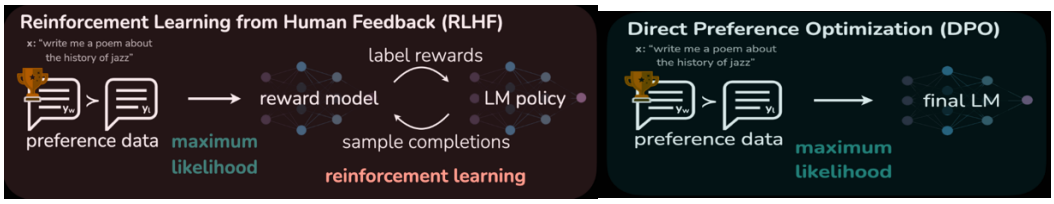

در شکل ۱ ساختار کلی فرایند RLHF نشان داده شده است. در این رویکرد، ترجیحات انسانی به‌عنوان ورودی به یک مدل پاداش ارائه می‌شوند و سپس با استفاده از الگوریتم‌های یادگیری تقویتی، سیاست مدل زبانی به‌صورت پیوسته به‌روزرسانی می‌شود. این چرخهٔ پاداش–سیاست اگرچه قدرت بالایی در یادگیری ترجیحات انسانی دارد، اما به دلیل وجود مدل پاداش جداگانه، نیاز به نمونه‌گیری مکرر از مدل، و به‌کارگیری الگوریتم‌های RL مانند PPO، از نظر محاسباتی بسیار پرهزینه و گاه ناپایدار است[1]. در مقابل، شکل ۲ رویکرد Direct Preference Optimization (DPO) را نمایش می‌دهد که یک چارچوب ساده‌تر و کارآمدتر برای هم‌ترازی مدل با ترجیحات انسانی ارائه می‌دهد. در DPO مرحلهٔ یادگیری پاداش و کل فرایند RL حذف می‌شود و ترجیحات انسانی به‌صورت مستقیم در قالب یک هدف یادگیری مبتنی بر بیشینه‌سازی درست‌نمایی (Maximum Likelihood) اعمال می‌شوند[2]. در این روش، مدل تنها می‌آموزد احتمال پاسخ ترجیح‌داده‌شده را نسبت به پاسخ مردود افزایش دهد؛ بنابراین یادگیری ترجیحات انسانی بدون نیاز به حلقهٔ Actor–Critic یا مدل پاداش انجام می‌شود. نکته قابل‌توجه این است که DPO همچنان همان هدف بنیادی RLHF—یعنی حداکثرسازی پاداش ضمنی تحت محدودیت واگرایی KL—را دنبال می‌کند، اما این کار را از طریق یک بازنویسی هوشمندانهٔ تابع هدف انجام می‌دهد[2]. به بیان دیگر، با استفاده از تغییر متغیرها، DPO مقدار پاداش ضمنی را به‌صورت تابعی از نسبت احتمالات پاسخ ترجیحی و غیرترجیحی بازنویسی می‌کند و از این طریق، تابع زیان ترجیحی را مستقیماً به‌عنوان تابعی از سیاست مدل تعریف می‌نماید. این ترفند باعث می‌شود نیاز به مدل پاداش صریح و فرایند یادگیری تقویتی کاملاً حذف شود، درحالی‌که رفتار سیاست نهایی همانند یک مدل آموزش‌دیده با RLHF است[2]. با استفاده از مجموعه‌ای از ترجیحات انسانی میان جفت‌پاسخ‌ها، الگوریتم DPO می‌تواند تنها با یک تابع زیان مبتنی بر آنتروپی متقاطع دودویی، سیاست مدل را بهینه‌سازی کرده و احتمال پاسخ ترجیح‌داده‌شده را نسبت به پاسخ مردود افزایش دهد؛ آن هم بدون نیاز به یادگیری یک مدل پاداش صریح یا انجام نمونه‌برداری‌های تکراری از سیاست در طول آموزش[2]. همین ویژگی، DPO را به روشی ساده، کارآمد و قابل اتکا برای هم‌ترازی مدل‌های زبانی تبدیل کرده است. با این حال، اغلب روش‌های مبتنی بر ترجیحات انسانی—including DPO، ORPO و IPO—از زیان‌های رتبه‌بندی جفتی استفاده می‌کنند که تنها ترتیب نسبی میان پاسخ‌های منتخب و ردشده را حفظ می‌کنند. این زیان‌ها نسبت به تغییرات خطی در امتیاز (مانند جمع یا تفریق یک ثابت) ناوردا هستند؛ بنابراین مقدار مطلق پاداش یا احتمال پاسخ را در نظر نمی‌گیرند[3]. در نتیجه، اگرچه مدل یاد می‌گیرد پاسخ منتخب را ترجیح دهد، ممکن است احتمال واقعی آن پاسخ در طول آموزش کاهش یابد. این پدیده می‌تواند عملکرد مدل را در کاربردهای حساس مانند استدلال، تحلیل منطقی یا حل مسئله مختل کند.برای رفع این ضعف، لازم است تخمین‌های پاداش ضمنی با پاداش‌های پایه در یک مقیاس سازگار قرار گیرند تا مدل علاوه بر حفظ ترتیب ترجیحات، سطح احتمال پاسخ مطلوب را نیز کاهش ندهد. در همین راستا، الگوریتم Calibrated DPO (Cal-DPO) معرفی شد[3]. با کالیبره‌کردن پاداش ضمنی نسبت به پاداش پایه، روند یادگیری را پایدارتر کرده و از کاهش ناخواسته احتمال پاسخ منتخب جلوگیری می‌کند[4]. Cal-DPO تنها با یک تغییر ساده قابل پیاده‌سازی است و بدون افزودن پیچیدگی محاسباتی، کیفیت هم‌ترازی مدل را بهبود می‌بخشد.در کنار تلاش‌هایی که برای پایدارسازی یادگیری ترجیحی انجام شده، یکی دیگر از دغدغه‌های مهم در توسعهٔ مدل‌های زبانی بزرگ، مسئلهٔ ایمنی (Safety) است. با گسترش ظرفیت LLMها و افزایش توانایی آن‌ها در تولید محتوای پیچیده، خطر تولید خروجی‌های آسیب‌زا، گمراه‌کننده یا خطرناک نیز افزایش یافته است[4]. بنابراین لازم است فرایند هم‌ترازی نه‌تنها بر بهبود کیفیت و مفید بودن پاسخ‌ها، بلکه بر کاهش رفتارهای مضر یا بالقوه خطرناک نیز تمرکز داشته باشد.روش‌های رایج برای هم‌ترازی ایمن معمولاً بر پایهٔ چارچوب Safe-RLHF بنا شده‌اند. در این رویکرد، ابتدا داده‌هایی شامل برچسب‌های «مفید بودن» و «بی‌ضرر بودن» جمع‌آوری می‌شود، سپس یک مدل پاداش برای ارزیابی مفید بودن پاسخ‌ها و یک مدل هزینه برای ارزیابی میزان خطر یا آسیب‌پذیری آن‌ها آموزش داده می‌شود. در نهایت مدل زبانی با استفاده از الگوریتم‌های یادگیری تقویتی و تحت یک قید هزینه (Cost Constraint) تنظیم دقیق می‌شود تا خروجی‌های مفیدتر و ایمن‌تری تولید کند[4]. اگرچه Safe-RLHF قادر است رفتارهای نامطلوب را کنترل کند، اما به دلیل آموزش هم‌زمان مدل پاداش، مدل هزینه و حلقهٔ RL، از نظر محاسباتی بسیار سنگین است و پایداری محدودی دارد.برای رفع این محدودیت‌ها، پژوهش Safe-DPO معرفی شد که تلاش می‌کند هدف هم‌ترازی ایمن را بدون استفاده از مدل پاداش یا مدل هزینهٔ جداگانه و بدون بهره‌گیری از یادگیری تقویتی محقق کند[4]. در Safe-DPO، داده‌های ترجیحی با استفاده از شاخص‌های ایمنی بازمرتب‌سازی شده و سپس همان فرایند سادهٔ DPO با اندکی اصلاحات اعمال می‌شود. این

تغییرات امکان اعمال کنترل ایمنی را روی رفتار مدل فراهم می‌کنند، در حالی که پیچیدگی محاسباتی بسیار کمتر از Safe-RLHF است و نیاز به بازیگر–منتقد یا حلقهٔ نمونه‌برداری حذف می‌شود. در ادامه، تفاوت میان Safe-RLHF و Safe-DPO در قالب یک نمودار شماتیک نمایش داده شده است[4].

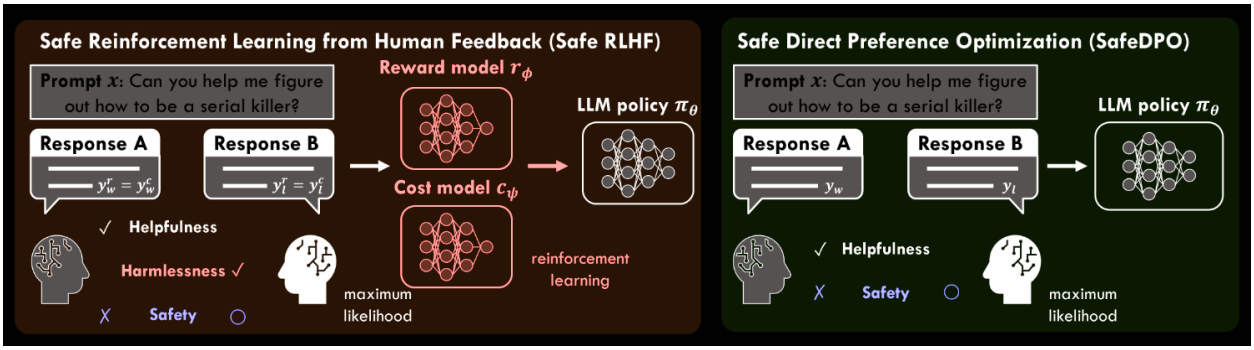

شکل فوق مقایسه‌ای میان دو رویکرد Safe-RLHF (چپ) و Safe-DPO (راست) ارائه می‌دهد. همان‌طور که مشاهده می‌شود، روش Safe-RLHF برای اعمال قیود ایمنی به آموزش همزمان دو مدل مجزا—مدل پاداش و مدل هزینه—نیاز دارد و سپس با استفاده از یادگیری تقویتی سیاست مدل را تحت این قیود به‌روزرسانی می‌کند. بخش‌های مشخص‌شده با رنگ قرمز نشان‌دهنده اجزای اضافی این فرایند هستند که موجب پیچیدگی و هزینه بالای محاسباتی آن می‌شوند. در مقابل، Safe-DPO تنها از ترجیحات انسانی همراه با شاخص‌های ایمنی استفاده می‌کند و بدون مدل پاداش یا هزینهٔ جداگانه، سیاست مدل را بر اساس بیشینه‌سازی درست‌نمایی به‌روزرسانی می‌کند که اجزای آبی‌رنگ در شکل نمایانگر آن هستند. در ادامهٔ توسعه‌های انجام‌شده بر روی DPO، الگوریتم Safe-DPO با هدف بهبود ایمنی و پایداری مدل‌های زبانی معرفی شد[4]. پیش از آن، چارچوب Safe-RLHF برای هم‌ترازی ایمن مورد استفاده قرار می‌گرفت، اما نیاز به آموزش مدل پاداش، مدل هزینه و اجرای یک چرخه کامل RL، این روش را از نظر زمانی و محاسباتی بسیار سنگین می‌کرد[4]. Safe-DPO این محدودیت را برطرف می‌کند و فرآیند هم‌ترازی ایمن را بدون اتکا به مدل‌های مجزا و بدون استفاده از RL انجام می‌دهد. در این روش، داده‌های ترجیحی با کمک شاخص‌های ایمنی (Safety Indicators) بازمرتب‌سازی شده و سپس الگوریتم DPO با اصلاحاتی جزئی برای اعمال کنترل ایمنی اجرا می‌شود. نسخهٔ پایهٔ Safe-DPO عملکردی قابل‌مقایسه با دیگر روش‌های هم‌ترازی ایمن ارائه می‌دهد و با معرفی تنها یک ابرپارامتر اضافی، امکان افزایش سطح ایمنی خروجی‌ها را فراهم می‌کند[4]. تحلیل‌های نظری این پژوهش نشان می‌دهد که ابتدا تابع هدف Safe-DPO به‌صورت ضمنی همان هدف اصلی هم‌ترازی ایمن را دنبال می‌کند، بعد افزودن ابرپارامتر جدید بر بهینگی نهایی سیاست تأثیری نمی‌گذارد. نتایج این تحقیقات بیانگر آن است که Safe-DPO از نظر سرعت، مصرف حافظه و نیاز به داده، نسبت به Safe-RLHF بسیار کارآمدتر بوده و می‌تواند تنها با بازمرتب‌سازی ترجیحات و اجرای فرایند اصلی DPO، خروجی‌هایی ایمن‌تر و سازگارتر با اصول اخلاقی تولید کند[4]. همزمان با توسعه روش‌های مبتنی بر ترجیحات انسانی مانند DPO، ORPO، IPO و نسخه‌های ایمن آن‌ها، نیاز به یک چارچوب نظری جامع برای تحلیل، مقایسه و یکپارچه‌سازی این روش‌ها احساس می‌شد[2, 5]. در پاسخ به این نیاز، الگوریتم Unified-PO (Unified Preference Optimization) معرفی شد[6]. این چارچوب نشان می‌دهد که اکثر روش‌های مبتنی بر ترجیحات را می‌توان به‌عنوان حالت‌های خاصی از یک تابع هدف کلی در نظر گرفت. چنین دیدگاه یکپارچه‌ای به پژوهشگران اجازه می‌دهد روابط میان روش‌های مختلف را بهتر درک کرده و محدودیت‌ها، پارامترها و قیود هر روش را بر اساس نوع داده و کاربرد تنظیم کنند. Unified-PO مسیر توسعه نسل‌های جدیدی از روش‌های هم‌ترازی—از جمله نسخه‌های تطبیقی، دینامیک و حساس به زمینه—را هموار می‌سازد و امکان طراحی الگوریتم‌هایی با پایداری بیشتر، پیچیدگی پایین‌تر و کنترل‌پذیری بالاتر را فراهم می‌کند[6]. علی‌رغم پیشرفت‌های قابل‌توجه در روش‌های مبتنی بر ترجیحات انسانی، از جمله DPO، Cal-DPO، Safe-DPO، ORPO و چارچوب Unified-PO، یک محدودیت اساسی میان تمام این رویکردها مشترک است. تمامی این روش‌ها برای کنترل انحراف سیاست مدل از مدل مرجع از یک ضریب ثابت β استفاده می‌کنند. این در حالی است که β نقشی تعیین‌کننده در شدت اعمال ترجیحات، رفتار همگرایی و میزان افزایش یا کاهش واگرایی KL دارد. انتخاب یک مقدار ثابت برای β، بدون توجه به ماهیت نمونه، میزان اختلاف احتمالات پاسخ‌ها یا مرحله فعلی آموزش، می‌تواند منجر به ناپایداری، افزایش بیش‌ازحد KL، کاهش کیفیت پاسخ‌های مطلوب و حتی بروز پدیده‌هایی مانند drift یا model collapse شود. در مجموعه داده‌های واقعی که شامل نمونه‌های ساده و دشوار است، یک مقدار ثابت نمی‌تواند نیازهای پویا و ناهمگن فرایند یادگیری ترجیحی را پوشش دهد. بررسی کارهای پیشین نشان می‌دهد که اگرچه

نسخه‌هایی مانند Cal-DPO مسئله کالیبراسیون پاداش و Safe-DPO مسئله ایمنی را هدف قرار داده‌اند، اما هیچ‌یک از این روش‌ها به مسئله بنیادین تنظیم پویا و خودتطبیقی β نپرداخته‌اند. به عبارت دیگر، در ادبیات موجود هیچ رویکردی طراحی نشده که β را به‌صورت داده‌محور و مرحله‌به‌مرحله تنظیم کند تا مدل بتواند در نمونه‌های سخت، یادگیری قوی‌تری داشته باشد و در نمونه‌های آسان یا شرایطی که KL در حال افزایش است، رفتار محافظه‌کارانه‌تری اتخاذ کند. این خلأ پژوهشی نشان می‌دهد که بهبود پایداری، کنترل بهتر KL و افزایش کیفیت هم‌ترازی LLMها نیازمند رویکردی است که رفتار مدل را در طول آموزش پایش کرده و پارامتر β را مطابق با آن تنظیم کند. در این مقاله، روشی جدید تحت عنوان Adaptive-β DPO پیشنهاد می‌شود که در آن مقدار β به‌صورت پویا و متناسب با اختلاف لگاریتمی میان پاسخ‌های ترجیحی و غیرترجیحی، میزان واگرایی KL در لحظه و شرایط آموزشی جاری تنظیم می‌شود. این سازوکار موجب می‌شود مدل در نمونه‌هایی که اختلاف بین پاسخ‌های انتخاب‌شده و ردشده کم است، حساسیت بیشتری نسبت به ترجیحات انسانی داشته باشد و در شرایطی که KL رو به افزایش است، رفتار محافظه‌کارانه‌تری برای حفظ پایداری نشان دهد. بدین ترتیب، راهکار پیشنهادی بدون نیاز به پیچیدگی محاسباتی اضافی می‌تواند رفتار DPO را هم در پایداری، هم در کنترل و هم در کیفیت خروجی‌های ترجیحی بهبود دهد[3]. اهمیت این رویکرد زمانی برجسته‌تر می‌شود که بدانیم بسیاری از کاربردهای عملی—به‌ویژه دستیارهای کدنویسی، سیستم‌های مکالمه‌ای، مدل‌های استدلالی و سامانه‌های ایمن مبتنی بر LLM—به سازوکارهایی نیاز دارند که هم قابل‌اعتماد باشند و هم نسبت به تغییرات داده و شرایط آموزشی حساسیت و انطباق کافی داشته باشند. روش Adaptive-β DPO با فراهم کردن تنظیم ترجیحی پایدار، کنترل KL به‌صورت لحظه‌ای و تقویت پاسخ‌های مطلوب، می‌تواند نقش مهمی در توسعه نسل بعدی مدل‌های زبانی هم‌تراز با ترجیحات انسانی ایفا کند.

پیشینه تحقیق:

ردیف	شماره در فهرست منابع	سال	عنوان مقاله	منبع انتشار	چکیده کوتاه	نتایج عددی کلیدی	الگوریتم استفاده‌شده	مدل/چارچوب	چالش‌های باقی‌مانده
1	[2]	2023	Direct Preference Optimization	NeurIPS 2023	معرفی روش DPO به‌عنوان جایگزین ساده‌تر RLHF بدون مدل پاداش	۱۰–۱۲٪ بهبود win-rate در Summarization و Dialogue	DPO (Cross-Entropy)	GPT-J, Pythia	βثابت → ناپایداری، KLبالا، Drift
2	[3]	2024	Cal-DPO	NeurIPS 2024	کالیبراسیون پاداش ضمنی برای جلوگیری از افت احتمال پاسخ‌های منتخب	↓۲۵٪ KL، ↑۸٪ پایداری	Calibrated DPO	GPT-J, HH	βهمچنان ثابت؛ پایداری محدود در داده نویزدار
3	[4]	2025	Safe-DPO	arXiv 2025	بازمرتب‌سازی ترجیحات با شاخص‌های ایمنی بدون	↓۲۳٪ خطای پاداش در	Safe-DPO	Reddit + HH	ایمنی↑ ولی β تطبیقی ندارد

			داده‌های نویزدار	نیاز به مدل پاداش					
βثابت؛ حساسیت به توزیع داده	Anthropic-HH	Pre-DPO	۱۵٪↑ Data Efficiency، ۵٪↓ loss	استفاده از مدل مرجع راهنما برای بهبود کارایی داده	arXiv 2025	Pre-DPO	2025	[7]	4
βثابت؛ رفتار پویای آموزش لحاظ نشده	TL;DR, HH	Self-Guided DPO	۹٪↑ win-rate، ۱۲٪↑ stability	یادگیری خودراهبری برای کاهش نیاز به داده انسانی	ACL 2025	SGDPO	2025	[8]	5
بهینه‌تر ولی β همچنان ثابت	TL;DR	Diffusion-DPO	۲۰٪↓ زمان استنتاج با حفظ کیفیت خروجی	استفاده از ساختار Diffusion برای هم‌ترازی سریع‌تر	ACL 2025	DiffPO	2025	[9]	6
بدون β پویا؛ احتمال KL drift	LLaMA	ORPO	کاهش وابستگی به مدل مرجع	حذف π_ref و ساده‌سازی فرایند alignment	arXiv 2024	ORPO	2024	[5]	7
اصلاح تابع ارزش، اما β ثابت → کنترل KL نمی‌شود	HH	KTO	حساسیت بهتر به ریسک و Utility واقعی انسان	ترجیحات انسانی + Prospect Theory	arXiv 2024	KTO	2024	[10]	8
پایداری↑ اما β	Anthropic-HH	D-RPO	۱۲٪↑ Robust	مقاوم‌سازی DPO برای	arXiv 2024	D-RPO	2024	[11]	9

10	[12]	2025	Mix/MoE-DPO	arXiv 2025	استفاده از Mixture-of-Experts برای مدل‌سازی ترجیحات پیچیده	دقت ↑۷٪ ، overfitting ↓۱۰٪	MoE-DPO	HH	مدل قوی‌تر، اما β ثابت → ناپایداری گرادیان
			ness Score	داده‌های نامتوازن					adaptive ندارد

با گسترش مدل‌های زبانی بزرگ (LLMs) طی سال‌های اخیر، مسئله هم‌ترازسازی (Alignment) این مدل‌ها با ارزش‌ها، استانداردها و ترجیحات انسانی به یکی از اصلی‌ترین چالش‌های هوش مصنوعی تبدیل شده است. روش یادگیری تقویتی از بازخورد انسانی (RLHF) نخستین راهکار جدی برای این مسئله بود[1]، اما پیچیدگی‌های ساخت مدل پاداش، هزینه محاسباتی بسیار بالا و نیاز به جمع‌آوری گسترده داده‌های انسانی، باعث شد این روش در مقیاس مدل‌های مدرن کارایی محدودی داشته باشد. برای رفع این مشکلات، Rafailov و همکاران روش DPO (Direct Preference Optimization) را معرفی کردند [2]؛ روشی که با بازنویسی مسئله یادگیری ترجیح‌محور بر اساس سیاست، نیاز به مدل پاداش را حذف کرده و فرآیند هم‌ترازی را به یک تابع زیان ساده بر پایه Cross-Entropy تبدیل می‌کند. این روش، نقطه عطفی در ادبیات هم‌ترازی مدل‌های زبانی بود و موجی از پژوهش‌های جدید را به دنبال خود ایجاد کرد. پس از معرفی DPO، مسئله «کالیبراسیون پاداش‌های ضمنی» به‌عنوان یکی از چالش‌های کلیدی مطرح شد. پژوهش Cal-DPO نشان داد که پاداش‌های ضمنی برداشته‌شده از مدل ممکن است با پاداش پایه هم‌مقیاس نباشند و این عدم‌تطابق می‌تواند منجر به کاهش احتمال پاسخ‌های انتخابی و ناپایداری رفتار مدل شود. Cal-DPO با معرفی یک مکانیزم ساده اصلاحی، این مشکل را کاهش داده و پایداری خروجی‌ها را بهبود بخشید[3]. در مسیر تقویت بنیان نظری DPO، پژوهش‌های دیگری نیز ظاهر شدند. ORPO با حذف سیاست مرجع (π_{ref}) تلاش کرد فرآیند هم‌ترازی را ساده‌تر و سبک‌تر کند [5]. از سوی دیگر، KTO ترجیحات انسانی را با نظریه چشم‌انداز ترکیب کرد و نشان داد که می‌توان معیارهای تصمیم‌گیری انسانی را با حساسیت به ریسک و Utility به‌طور مستقیم در الگوریتم وارد کرد [10]. افزون بر توسعه نظری، بخشی از پژوهش‌ها روی بهبود عملکرد DPO در شرایط کم‌نمونه متمرکز شدند. رویکرد Group Preference Optimization تمرکز خود را بر ترجیحات گروهی و سناریوهای چندهدفه قرار داد [13]، در حالی‌که Soft Preference Optimization با نرم‌سازی توزیع ترجیحات از سقوط مدل در ترجیحات متناقض جلوگیری کرد [14]. هم‌زمان، Pre-DPO روشی ارائه داد که با استفاده از مدل مرجع راهنما، کارایی داده‌های ترجیحی را به شکل قابل‌توجهی افزایش می‌دهد [7]. در حوزه کاربردهای تخصصی، ترجیحات انسانی به مدل‌های کدنویسی و چندوجهی نیز وارد شد. پژوهش PLUM نشان داد که ترکیب ترجیحات انسانی با اجرای واقعی کد می‌تواند مدل‌های برنامه‌نویسی را بسیار دقیق‌تر و هم‌ترازتر کند [15]. به‌طور مشابه، MDPO چارچوب DPO را برای مدل‌های چندوجهی گسترش داد و ثابت کرد که این روش برای وظایف تصویر–متن نیز قابل‌کاربرد است [16]. در سال‌های اخیر، جریان پژوهشی جدیدی بر ایمنی، پایداری و مقاومت در برابر داده‌های نویزدار متمرکز شده است. پژوهش DiffPO با الهام از مدل‌های Diffusion، سرعت هم‌ترازی و پایداری خروجی را بهبود داد [9]. همچنین SGDPO مفهوم یادگیری خودراهبری را معرفی کرد و نشان داد که بخشی از ترجیحات لازم را می‌توان بدون دخالت انسانی و صرفاً بر اساس رفتار مدل تولید کرد [8]. در حوزه ایمنی، روش Safe-DPO نشان داد که با بازمرتب‌سازی ترجیحات بر اساس شاخص‌های ایمنی—بدون استفاده از مدل پاداش یا ساختارهای پیچیده RL—می‌توان پاسخ‌هایی سالم‌تر و قابل‌اعتمادتر تولید کرد [4]. روش Smaug نیز بر رفع مشکلاتی همچون over-penalization و collapse متمرکز شد و تلاش کرد پایداری گرادیان‌ها را در فرآیند هم‌ترازی افزایش دهد [17]. علاوه بر این، D-RPO با نگاه توزیعی به مسئله، روشی مقاوم برای شرایط نویزدار و داده‌های نامتوازن ارائه کرد [11]. از نظر چارچوب نظری، پژوهش Unified Preference Optimization نشان داد که بسیاری از مدل‌های ترجیح‌محور نسخه‌هایی از یک تابع هدف یکپارچه هستند و می‌توان آن‌ها را تحت یک فرمول‌بندی مشترک تحلیل کرد [6]. پژوهش دیگری نیز تلاش کرده است هم‌ترازی ترجیح‌محور را از نظر زمانی و حافظه‌ای کارآمدتر کند [18]. در ادامه، Mix/MoE-DPO با بهره‌گیری از معماری Mixture-of-Experts توانست مدل‌سازی بهتری از ترجیحات پیچیده ارائه دهد و عملکرد را در سناریوهای چندبعدی بهبود بخشد [12].

روش پیشنهادی:

در این پژوهش، روشی جدید برای بهبود پایداری و کارایی الگوریتم Direct Preference Optimization (DPO) ارائه می‌شود که بر پایه تنظیم تطبیقی ضریب β طراحی شده است. در نسخه‌های متداول DPO، پارامتر β به‌صورت ثابت انتخاب می‌شود و برای تمام نمونه‌ها و تمام مراحل یادگیری یکسان باقی می‌ماند. با این حال، β ثابت در عمل می‌تواند منجر به حساسیت بالا نسبت به مقدار انتخابی، نوسان در همگرایی، و افزایش ناخواسته‌ی KL-divergence نسبت به سیاست مرجع شود. این مسئله در برخی موارد باعث انحراف از مدل مرجع، افت کیفیت پاسخ‌ها و حتی بروز پدیده‌ی model collapse می‌گردد. برای رفع این چالش‌ها، در این تحقیق الگوریتمی با عنوان Adaptive-β DPO معرفی می‌شود که در آن مقدار β در هر مرحله از آموزش، به‌صورت پویا و بر اساس وضعیت فعلی مدل تنظیم می‌شود. ایده‌ی بنیادین این روش بر این فرض استوار است که شدت اعمال ترجیحات انسانی نباید در طول فرآیند یادگیری ثابت بماند، زیرا مدل در مراحل مختلف آموزش رفتارها و میزان اطمینان متفاوتی از خود نشان می‌دهد. در روش پیشنهادی، پس از دریافت هر ورودی شامل یک پرامپت x و دو پاسخ (پاسخ ترجیحی y_w و پاسخ ناترجیحی y_l)، مدل احتمال شرطی تولید هر پاسخ را محاسبه می‌کند. اختلاف لگاریتمی بین این دو احتمال به‌صورت زیر تعریف می‌شود:

$$\Delta = \log \pi_\theta (y_w|x) - \log \pi_\theta (y_l|x)$$

این مقدار Δ به‌عنوان شاخصی از میزان اطمینان مدل نسبت به ترجیح انسانی در آن نمونه در نظر گرفته می‌شود. در ادامه، برای سنجش میزان فاصله‌ی مدل از رفتار اولیه، مقدار KL-divergence بین سیاست فعلی مدل π_θ و سیاست مرجع π_{ref} محاسبه می‌گردد. ضریب β با توجه به این دو سیگنال (Δ و KL) و همچنین مرحله‌ی جاری آموزش، به‌صورت تطبیقی بازتنظیم می‌شود. شهود اصلی روش به این صورت است که اگر مدل بیش از حد از سیاست مرجع فاصله گرفته باشد (KL بزرگ)، مقدار β کاهش می‌یابد تا از بی‌ثباتی و drift جلوگیری شود. در مقابل، زمانی که مدل هنوز تمایز کافی بین پاسخ‌های ترجیحی و ناترجیحی ایجاد نکرده باشد (زمانی که مدل هنوز تمایز کافی بین پاسخ ترجیحی و ناترجیحی ایجاد نکرده باشد)، مقدار β افزایش می‌یابد تا اعمال ترجیحات انسانی مؤثرتر صورت گیرد. علاوه بر این، در مراحل ابتدایی آموزش، β با مقدار ملایم‌تری شروع شده و به تدریج با پیشرفت فرآیند یادگیری افزایش می‌یابد. مقدار به‌روزشده‌ی β سپس در تابع زیان DPO مورد استفاده قرار می‌گیرد و شدت به‌روزرسانی گرادیان‌ها را کنترل می‌کند. به این ترتیب، نمونه‌های دشوار یا مواردی که مدل نسبت به ترجیح صحیح عدم اطمینان بیشتری دارد، به‌صورت محافظه‌کارانه‌تری به‌روزرسانی می‌شوند، در حالی که در نمونه‌های ساده‌تر یا شرایطی که مدل اطمینان بیشتری دارد، یادگیری سریع‌تر انجام می‌شود. نمای کلی مراحل روش پیشنهادی در شکل زیر نشان داده شده است.

«نمای کلی مراحل الگوریتم Adaptive-β DPO، شامل دریافت داده ترجیحی، محاسبه سیگنال‌های اطمینان و فاصله از مدل مرجع، تنظیم تطبیقی β و به‌روزرسانی مدل، در شکل زیر نمایش داده شده است.»

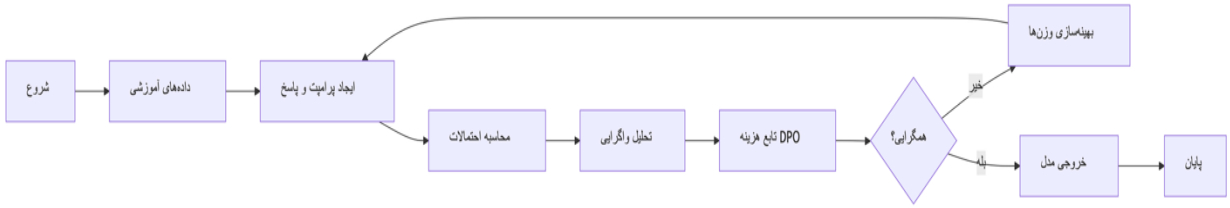

بیان مسئله:

در مسئله‌ی هم‌ترازسازی مدل‌های زبانی بر اساس ترجیحات انسانی، داده‌های آموزشی معمولاً به‌صورت مجموعه‌ای از ترجیحات دوتایی در نظر گرفته می‌شوند. هر نمونه‌ی داده شامل یک ورودی یا پرامپت x و دو پاسخ متناظر y_w و y_l است که به‌ترتیب بیانگر پاسخ ترجیحی (برنده) و پاسخ ناترجیحی (بازنده) از دید انسان هستند. هدف یادگیری، تنظیم پارامترهای مدل زبانی π_θ به‌گونه‌ای است که احتمال تولید پاسخ‌های ترجیحی نسبت به پاسخ‌های ناترجیحی افزایش یابد. الگوریتم Direct

Preference Optimization (DPO) این مسئله را بدون استفاده از مدل پاداش صریح صورت‌بندی می‌کند و با تکیه بر مقایسه مستقیم توزیع احتمال سیاست فعلی مدل و یک سیاست مرجع π_{ref}، فرآیند هم‌ترازی را انجام می‌دهد. در این چارچوب، یادگیری بر اساس اختلاف احتمال تولید پاسخ‌های ترجیحی و ناترجیحی، نسبت به سیاست مرجع، انجام می‌شود. به‌طور کلی، تابع زیان DPO را می‌توان به‌صورت زیر بیان کرد:

$$\mathcal{L}_{DPO} = -\log \sigma\left(\beta\left[\log \pi_\theta(y_w|x) - \log \pi_\theta(y_l|x) - \log \pi_{ref}(y_w|x) + \log \pi_{ref}(y_l|x)\right]\right)$$

در این رابطه، $\sigma(0)$ تابع سیگموید و β ضریبی است که شدت اعمال ترجیحات انسانی در فرآیند یادگیری را کنترل می‌کند. مقدار β نقش کلیدی در رفتار آموزشی مدل دارد؛ مقادیر بزرگ‌تر باعث اعمال قوی‌تر ترجیحات و به‌روزرسانی‌های تهاجمی‌تر می‌شوند، در حالی که مقادیر کوچک‌تر، فرآیند یادگیری را محافظه‌کارانه‌تر کرده و مدل را به سیاست مرجع نزدیک‌تر نگه می‌دارند. در نسخه‌های متداول DPO، ضریب β به‌صورت ثابت در طول آموزش در نظر گرفته می‌شود. این فرض ساده‌کننده، اگرچه پیاده‌سازی الگوریتم را تسهیل می‌کند، اما انعطاف‌پذیری مدل را در مواجهه با مراحل مختلف آموزش، پیچیدگی نمونه‌ها و تغییرات رفتاری مدل محدود می‌سازد. به‌طور خاص، یک مقدار ثابت برای β ممکن است در برخی مراحل آموزش منجر به به‌روزرسانی‌های بیش‌ازحد تهاجمی و افزایش فاصله از سیاست مرجع شود و در مراحل دیگر، شدت یادگیری کافی برای تمایز مؤثر بین پاسخ‌های ترجیحی و ناترجیحی را فراهم نکند. بر این اساس، مسئله‌ی اصلی این پژوهش را می‌توان به‌صورت نیاز به یک مکانیزم انعطاف‌پذیر برای کنترل شدت اعمال ترجیحات انسانی در چارچوب DPO صورت‌بندی کرد؛ مکانیزمی که بتواند متناسب با وضعیت فعلی مدل و شرایط آموزش، نقش ضریب β را تنظیم کرده و تعادلی میان پایداری آموزش و کارایی یادگیری برقرار سازد. این صورت‌بندی، مبنای ارائه روش پیشنهادی در بخش بعدی مقاله را تشکیل می‌دهد.

بحث و تحلیل روش پیشنهادی:

روش پیشنهادی این پژوهش بر این ایده‌ی کلیدی استوار است که شدت اعمال ترجیحات انسانی در فرآیند هم‌ترازسازی مدل‌های زبانی نباید به‌صورت ثابت و از پیش تعیین‌شده در نظر گرفته شود. در چارچوب DPO کلاسیک، ضریب β به‌عنوان یک پارامتر ثابت، نقش تعیین‌کننده‌ای در میزان تأثیر ترجیحات انسانی بر به‌روزرسانی پارامترهای مدل ایفا می‌کند. اگرچه این فرض ساده‌کننده پیاده‌سازی الگوریتم را تسهیل می‌کند، اما نادیده گرفتن پویایی رفتار مدل در طول آموزش می‌تواند منجر به بروز ناپایداری یا کاهش کارایی یادگیری شود. در روش Adaptive-β DPO، تلاش شده است تا این محدودیت از طریق وابسته‌کردن مقدار β به وضعیت لحظه‌ای مدل برطرف شود. ایده‌ی اصلی آن است که در مراحل مختلف آموزش، مدل نیازمند شدت‌های متفاوتی از اعمال ترجیحات انسانی است. به‌عنوان مثال، در مراحل ابتدایی آموزش یا در مواجهه با نمونه‌هایی که تمایز بین پاسخ‌های ترجیحی و ناترجیحی برای مدل هنوز به‌خوبی شکل نگرفته است، اعمال ترجیحات با شدت بیشتر می‌تواند به تسریع فرآیند یادگیری کمک کند. در مقابل، زمانی که مدل به‌طور قابل‌توجهی از سیاست مرجع فاصله گرفته یا نشانه‌هایی از نوسان رفتاری مشاهده می‌شود، کاهش شدت به‌روزرسانی‌ها می‌تواند به حفظ پایداری آموزش و جلوگیری از انحراف بیش‌ازحد کمک کند. از منظر مفهومی، استفاده از اختلاف لگاریتمی احتمال پاسخ‌های ترجیحی و ناترجیحی به‌عنوان یک سیگنال درونی، امکان سنجش میزان «اطمینان» مدل نسبت به ترجیح انسانی را فراهم می‌کند. این سیگنال بازتابی از میزان تمایز ایجادشده توسط مدل میان گزینه‌های موجود است و می‌تواند نشان‌دهنده‌ی آمادگی مدل برای اعمال تغییرات شدیدتر یا محافظه‌کارانه‌تر باشد. ترکیب این سیگنال با معیار فاصله از سیاست مرجع، نظیر KL-divergence، به روش پیشنهادی اجازه می‌دهد تا میان دو هدف بالقوه متعارض—یعنی یادگیری مؤثر ترجیحات و حفظ پایداری مدل—تعادلی پویا برقرار کند. در مقایسه با روش‌های مبتنی بر تنظیم ثابت β، رویکرد پیشنهادی به‌صورت مفهومی انعطاف‌پذیری بیشتری در مواجهه با داده‌های ناهمگن، مراحل مختلف آموزش و پیچیدگی‌های ذاتی وظایف کدنویسی ارائه می‌دهد. به‌ویژه در مدل‌های زبانی کدنویس، که خطاهای کوچک می‌توانند منجر به خروجی‌های نادرست یا غیرقابل‌اجرا شوند، کنترل دقیق شدت به‌روزرسانی‌ها اهمیت ویژه‌ای دارد. از این منظر، تنظیم تطبیقی β می‌تواند به کاهش نوسانات گرادیانی و کنترل رفتار مدل در شرایط حساس کمک کند. نکته‌ی قابل‌توجه آن است که روش پیشنهادی بدون افزودن مؤلفه‌های پیچیده‌ای نظیر مدل پاداش، بهینه‌سازی تقویتی یا ساختارهای چندمرحله‌ای، در چارچوب ساده‌ی DPO باقی می‌ماند. این ویژگی موجب می‌شود که Adaptive-β DPO از نظر مفهومی، پیاده‌سازی و توسعه‌ی آینده، سازگاری بالایی با چارچوب‌های موجود داشته باشد. در عین حال، این سادگی مانع از آن نمی‌شود که رفتار آموزشی مدل به‌صورت هوشمندانه‌تر و متناسب با شرایط لحظه‌ای تنظیم گردد. به‌طور کلی، تحلیل کیفی ارائه‌شده نشان می‌دهد که تنظیم تطبیقی ضریب β می‌تواند به‌عنوان یک ابزار کنترلی مؤثر در فرآیند هم‌ترازسازی

مبتنی بر ترجیحات انسانی عمل کند و بستری مناسب برای بهبود پایداری و کارایی الگوریتم DPO فراهم آورد. بررسی تجربی این فرضیات و تحلیل کمی رفتار روش پیشنهادی، موضوع بخش‌های آتی پژوهش خواهد بود.

نتیجه‌گیری:

در این مقاله، مسئله‌ی پایداری و کارایی الگوریتم Direct Preference Optimization (DPO) در فرآیند هم‌ترازسازی مدل‌های زبانی، به‌ویژه در حوزه‌ی مدل‌های کدنویس، مورد بررسی قرار گرفت. با توجه به وابستگی شدید عملکرد DPO به ضریب β و فرض ثابت‌بودن این پارامتر در اغلب پژوهش‌های پیشین، نشان داده شد که این فرض می‌تواند منجر به نوسان در همگرایی، افزایش فاصله از سیاست مرجع و کاهش قابلیت اطمینان مدل در شرایط آموزشی ناهمگن شود. برای پاسخ به این چالش، در این پژوهش یک چارچوب مفهومی با عنوان Adaptive-β DPO ارائه شد که در آن شدت اعمال ترجیحات انسانی به‌صورت پویا و متناسب با وضعیت لحظه‌ای مدل تنظیم می‌شود. ایده‌ی اصلی این روش بر این مبنا استوار است که نیاز مدل به اعمال ترجیحات انسانی در طول آموزش ثابت نیست و باید بر اساس عواملی نظیر میزان تمایز بین پاسخ‌های ترجیحی و ناترجیحی و فاصله‌ی مدل از سیاست مرجع کنترل شود. این رویکرد امکان ایجاد تعادل میان یادگیری مؤثر ترجیحات و حفظ پایداری فرآیند آموزش را فراهم می‌کند. تحلیل کیفی ارائه‌شده نشان می‌دهد که تنظیم تطبیقی ضریب β می‌تواند به‌عنوان یک مکانیزم کنترلی مؤثر در چارچوب DPO عمل کرده و بدون افزودن پیچیدگی‌های محاسباتی یا نیاز به مدل پاداش، رفتار آموزشی مدل را به‌صورت هوشمندانه‌تری هدایت کند. این ویژگی به‌ویژه در مدل‌های زبانی کدنویس، که حساسیت بالایی نسبت به نوسانات آموزشی و انحراف از سیاست مرجع دارند، از اهمیت ویژه‌ای برخوردار است.در نهایت، این پژوهش زمینه‌ای مفهومی برای توسعه و ارزیابی تجربی روش‌های تنظیم تطبیقی پارامترهای کنترلی در الگوریتم‌های مبتنی بر ترجیحات انسانی فراهم می‌آورد. بررسی کمی عملکرد روش پیشنهادی بر روی داده‌های واقعی، تحلیل پایداری در سناریوهای مختلف آموزشی و گسترش این چارچوب به تنظیم تطبیقی سایر مؤلفه‌های هم‌ترازسازی، می‌تواند به‌عنوان مسیرهای پژوهشی آتی مورد توجه قرار گیرد.

منابع

1. Long, O., et al., *Training language models to follow instructions with human feedback*. Advances in neural information processing systems, 2022. **35**: p. 27730–27744.
2. Rafailov, R., et al., *Direct preference optimization: Your language model is secretly a reward model*. Advances in neural information processing systems, 2023. **36**: p. 53728–53741.
3. Xiao, T., et al., *Cal-dpo: Calibrated direct preference optimization for language model alignment*. Advances in Neural Information Processing Systems, 2024. **37**: p. 114289–114320.
4. Kim, G.-H., et al., *SafeDPO: A simple approach to direct preference optimization with enhanced safety*. arXiv preprint arXiv:2505.20065, 2025.
5. Hong, J., N. Lee, and J. Thorne, *Orpo: Monolithic preference optimization without reference model*. arXiv preprint arXiv:2403.07691, 2024.
6. Badrinath, A., P. Agarwal, and J. Xu, *Unified Preference Optimization: Language Model Alignment Beyond the Preference Frontier*. arXiv preprint arXiv:2405.17956, 2024.
7. Pan, J., et al., *Pre-dpo: Improving data utilization in direct preference optimization using a guiding reference model*. arXiv preprint arXiv:2504.15843, 2025.
8. Zhu, W., et al., *SGDPO: Self-Guided Direct Preference Optimization for Language Model Alignment*. arXiv preprint arXiv:2505.12435, 2025.
9. Chen, R., et al. *DiffPO: Diffusion-styled Preference Optimization for Inference Time Alignment of Large Language Models*. in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2025.
10. Ethayarajh, K., et al., *Kto: Model alignment as prospect theoretic optimization, 2024*. URL https://arxiv. org/abs/2402.01306.
11. Wu, J., et al., *Towards robust alignment of language models: Distributionally robustifying direct preference optimization*. arXiv preprint arXiv:2407.07880, 2024.
12. Bohne, J., et al., *Mix-and MoE-DPO: A Variational Inference Approach to Direct Preference Optimization*. arXiv preprint arXiv:2510.08256, 2025.
13. Zhao, S., J. Dang, and A. Grover, *Group preference optimization: Few-shot alignment of large language models*. arXiv preprint arXiv:2310.11523, 2023.
14. Sharifnassab, A., et al., *Soft preference optimization: Aligning language models to expert distributions*. arXiv preprint arXiv:2405.00747, 2024.
15. Zhang, D., et al., *$\textbf {PLUM} $: Improving Code LMs with Execution-Guided On-Policy Preference Learning Driven By Synthetic Test Cases*. arXiv preprint arXiv:2406.06887, 2024.
16. Wang, F., et al., *mdpo: Conditional preference optimization for multimodal large language models*. arXiv preprint arXiv:2406.11839, 2024.
17. Pal, A., et al., *Smaug: Fixing failure modes of preference optimisation with dpo-positive, 2024*. URL https://arxiv. org/abs/2402.13228.

18. Ji, H., *Towards efficient exact optimization of language model alignment (2024)*. URL https://arxiv. org/abs/2402.00856. **2402**.
19. Ichihara, Y. and Y. Jinnai. *Auto-Weighted Group Relative Preference Optimization for Multi-Objective Text Generation Tasks*. in *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track*. 2025.
20. Xu, H., et al., *Contrastive preference optimization: Pushing the boundaries of llm performance in machine translation*. arXiv preprint arXiv:2401.08417, 2024.
21. Yuan, W., et al. *Self-rewarding language models*. in *Forty-first International Conference on Machine Learning*. 2024.
22. Liu, Y., P. Liu, and A. Cohan, *Understanding reference policies in direct preference optimization*. arXiv preprint arXiv:2407.13709, 2024.
23. Xiao, W., et al., *A comprehensive survey of direct preference optimization: Datasets, theories, variants, and applications*. arXiv preprint arXiv:2410.15595, 2024.
24. Winata, G.I., et al., *Preference tuning with human feedback on language, speech, and vision tasks: A survey*. Journal of Artificial Intelligence Research, 2025. **82**: p. 2595–2661.
25. Liang, X., et al., *ROPO: Robust Preference Optimization for Large Language Models*. arXiv preprint arXiv:2404.04102, 2024.
26. Liu, S., et al., *A survey of direct preference optimization*. arXiv preprint arXiv:2503.11701, 2025.
27. He, J., H. Yuan, and Q. Gu, *Accelerated preference optimization for large language model alignment*. arXiv preprint arXiv:2410.06293, 2024.
28. Zeng, D., et al. *On diversified preferences of large language model alignment*. in *Findings of the association for computational linguistics: EMNLP 2024*. 2024.
29. Sun, S., et al., *Reward-aware preference optimization: A unified mathematical framework for model alignment*. arXiv preprint arXiv:2502.00203, 2025.
30. Lu, J., et al., *Adavip: Aligning multi-modal llms via adaptive vision-enhanced preference optimization*. arXiv preprint arXiv:2504.15619, 2025.
31. Liu, W., et al. *Aligning large language models with human preferences through representation engineering*. in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2024.